

Extração de Inteligência Gerencial a partir de Atas de Reunião Não Estruturadas

Problema de Pesquisa: Como um framework analítico baseado em NLP pode ser utilizado para identificar e monitorar longitudinalmente problemas organizacionais recorrentes em atas corporativas não estruturadas?



Volume

Centenas de atas por ano entre as áreas de negocio — revisão manual e inviável



Recorrência

Os mesmos problemas reaparecem ao longo dos meses e áreas sem detecção sistemática



Invisibilidade

Nenhum mecanismo estruturado para rastrear a persistência ou escalada de problemas

Motivação e Justificativa

POR QUE ISSO IMPORTA

Lacuna no aprendizado organizacional

As atas são fontes ricas de conhecimento institucional, mas permanecem amplamente não processadas após a distribuição.

Risco de governança

Problemas recorrentes não detectados sinalizam falhas sistêmicas na gestão de projetos e fornecedores.

Escala

O corpus abrange 11 áreas de negócio ao longo de múltiplos anos — uma escala que exige automação.

Perguntas de Pesquisa

RQ1

A classificação supervisionada com NLP consegue identificar de forma confiável entradas relacionadas a problemas em atas corporativas?

RQ2

O clustering semântico é capaz de consolidar problemas organizacionais lexicalmente diferentes, mas semanticamente similares?

RQ3

Quais insights gerenciais emergem do monitoramento longitudinal de problemas organizacionais recorrentes?

Trabalhos Relacionados

O que já foi feito neste campo

Classificação de Textos

→ Advances in pre-trained language models for domain-specific text classification: A systematic review. (Rostam et al., 2025)

→ Comparing BERT against tradicional machine learning text classification. (Gonzalez-Carvajal & Garrido-Merchan, 2020)

→ Lacuna: Classificar problemas em atas internas é um caso de uso não coberto pela literatura.

Clustering e Modelagem de Tópicos

→ Semantic-driven topic modelling using transformer-based embeddings and clustering algorithms. (Mersha et al., 2024)

→ BERTopic: Neural topic modeling with a class-based TF-IDF procedure. (Grootendorst, 2022)

→ Lacuna: Combinar similaridade semântica e proximidade temporal numa única matriz de distância para clustering de problemas recorrentes é uma contribuição metodológica ainda ausente na literatura.

Rastreamento Longitudinal de Problemas

→ Modelling and detecting company risks from News. (Pei et al., 2024)

→ Sentiment polarity identification in financial news: A cohesion-based approach. (Devitt & Ahmad, 2007)

→ Lacuna: Não existe na literatura um framework que rastreie longitudinalmente a persistência de problemas a partir de registros internos não estruturados, como atas de reunião.

Este trabalho integra as três vertentes — um pipeline que classifica, agrupa e rastreia longitudinalmente problemas em atas corporativas reais.

Proposta Metodológica

01

RQ1

Ingestão de Dados

374 atas de reunião
3.603 segmentos
após limpeza

02

RQ1

Classificação Supervisionada

SVM + TF-IDF
(F1 = 0,88)
Otimização do threshold

03

RQ2

Clustering Semântico

HDBSCAN
Semântico 75% +
Temporal 25%

04

RQ3

Análise Longitudinal

Métricas de persistência
por cluster e área
Rastreamento de timeline

Base de Dados

Corpus: 374 atas de reunião · 11 áreas ·
3 anos

Treino: 2.384 segmentos rotulados ·
33,7% problemas

Benchmark: 9 combinações de modelos: SVM /
NB / RF x TF-IDF / W2V / BERT

Resultados – RQ1

RQ1 — Classificação

0,88

F1

0,90

Precisão

0,91

Recall

Melhor modelo: SVM + TF-IDF

963


Problemas

2.640


Não-problemas

0,009

Threshold de
otimização



Comparação entre classificadores e vetorização (F1 - Test Set)



Resultados – RQ2

RQ2 — Clustering

59

Clusters formados

315

Problemas agrupados
(32,7%)

648

Problemas isolados
(67,3%)

69%

Taxa de ruído

0,67

Sillhouette Score (>
0,25)

0,92

Similaridade de
cosseno intra-cluster
(> 0,65)

5,2/0,39

Tamanho médio/Coef.
Variação dos Clusters

26,72


Calinski-Harabasz
Index (> melhor)

1,03

Davies-Bouldin Index
(< 1,0)

Modelo utilizado: S2V + HDBSCAN

Visualização dos Problemas Clusterizados (HDBSCAN)



Resultados – RQ3

1,3

persistência média (meses)

9

persistência máxima


5,8%

problemas crônicos (>3m)

22

ativos no último período

Problemas por área de negócio





ESTUDO DE CASO

O problema crônico nº 1: 9 meses em aberto



Requalificação P36 — Módulo Expedição (Área 10)

15 menções · mar–nov/2024 · atrasos recorrentes sinalizados pelo fornecedor **C19** · risco direto ao go-live da operação.

mai/24



Atraso no início
do desenvolvimento

jun/24



Velocidade do squad
abaixo do planejado

set/24



Novo atraso C19;
replanejamento

21/10



Go-live adiado
por pendências

18/11



Nova postergação
do go-live

Visível apenas porque o framework agrega 15 trechos textualmente distintos num único problema rastreável.



Os clusters recorrentes têm assinatura de negócio

Problema canônico (anonimizado)	Área	Menções	Natureza
Atrasos na requalificação do módulo de expedição (P36); fornecedor C19	10	14	Atraso crônico de fornecedor
Produto congelado (P48/P76/P77) até substituição pelo P39	6	13	Decisão de portfólio
Tender atrasado p/ troca do fornecedor C2 (P46/P79); +R\$2 MM	3	8	Suprimentos / orçamento
Migração AIDE cancelada — sem orçamento nem time	7	7	Restrição de recursos
Falha de especificação do fornecedor C48 — inspeção por câmera (P46)	9	6	Falha técnica / retrabalho
Negociação de redução de 20% no custo de Cloud (P65/C22)	3	6	Iniciativa de custo

Três temas dominam a cauda crônica: risco de fornecedor, restrições de orçamento/recurso e atrasos de entrega.



VALOR DE NEGÓCIO · 1

O que o framework expõe à gestão



Risco de fornecedor concentrado

C19, C2 e C48 recorrem em clusters distintos. Insumo direto para gestão de fornecedores e contratos.



O que deveria ser simples e arrasta

Aprovações, orçamentos e aditivos parados — alta persistência, baixa complexidade. Onde a governança rende mais.



Estouros de orçamento e recurso

Tender com +R\$2 MM; migração cancelada por falta de verba e time. Sinais de lacuna de planejamento.



Mapa de calor por área

Área 10 concentra 18% dos problemas (perfil operacional). Risco difuso entre 11 áreas (entropia 0,91).



VALOR DE NEGÓCIO · 2

Apoio à decisão em operação



Watchlist automática

25 problemas ativos no último mês — lista pronta para a próxima reunião de status, sem esforço manual.



Triagem em segundos

Centenas de atas/ano × 11 áreas tornam a revisão manual inviável. O pipeline entrega priorização imediata.



Atas viram um KPI de governança monitorável

O indicador de persistência converte conhecimento tácito disperso em uma métrica acompanhável, **fechando o loop de aprendizado organizacional**: a ata deixa de ser arquivo morto e passa a orientar a próxima decisão.



CONCLUSÕES

O que respondemos



RQ1

Sim — SVM + TF-IDF sobre texto cru identifica problemas com F1 de 0,87 no teste.



RQ2

Sim — a distância semântico-temporal forma 57 clusters internamente coesos de problemas recorrentes.



RQ3

O monitoramento expõe problemas crônicos, risco de fornecedor e uma watchlist acionável.

Contribuição: transformar atas — arquivo morto — num KPI de governança monitorável, fechando o loop de aprendizado organizacional.